RESUMEN EJECUTIVO

Análisis de Movilidad Urbana y Productividad Económica en LATAM

10 ciudades latinoamericanas · TomTom Traffic Index + OECD Cities 2024

Preparado por: Flavio César Ortiz Santos
Analista de Datos Junior | TripleTen Bootcamp

Herramientas: Python · pandas · NumPy · scikit-learn · seaborn · matplotlib

Visualizaciones mejoradas con apoyo de Inteligencia Artificial

1. Contexto del Análisis [C]

La Dirección de Inversión en Infraestructura requirió un análisis para identificar en qué ciudades latinoamericanas conviene priorizar inversión en transporte público y movilidad urbana. La hipótesis central del estudio es que una mayor congestión vehicular se asocia con menor productividad económica, medida por el PIB per cápita de la ciudad.

El análisis buscó responder dos preguntas de negocio:

- **P1.** ¿Existe una correlación entre el nivel de congestión vehicular y el PIB per cápita de las ciudades latinoamericanas?
- **P2.** ¿Qué ciudades muestran el mayor impacto negativo de la congestión sobre su productividad y deberían ser priorizadas para inversión?

1.1 Fuentes de Datos

- TomTom Traffic Index — Dataset transaccional con 1,004,464 registros horarios de congestión por ciudad: jams_delay, traffic_index_live, jams_length_in_kms, jams_count, mins_delay
- OECD Cities 2024 — Dataset económico con 30 ciudades: city_gdp_capita, unemployment_pct, pm25, population_m

1.2 Variables Clave

- jams_delay — Retraso acumulado por congestión (minutos). Métrica principal de congestión vehicular
- city_gdp_capita — PIB per cápita de la ciudad en USD. Proxy de productividad económica
- MinMaxScaler — Normalización para comparar variables de diferente escala en una misma visualización

2. Proceso de Análisis

Paso 1 — Carga y exploración inicial

Se importaron las librerías pandas, NumPy, seaborn y matplotlib. Se cargaron los dos datasets desde archivos CSV y se realizó una revisión preliminar de estructura, tipos de datos y dimensiones. El dataset de tráfico contiene 1,004,464 registros; el dataset económico contiene 30 ciudades con datos del año 2023.

Paso 2 — Limpieza y preparación

Se estandarizaron los nombres de columna a formato snake_case en ambos datasets para facilitar la integración. En el dataset económico se corrigieron los formatos numéricos: se eliminaron separadores de miles y se reemplazaron comas por puntos en city_gdp_capita, unemployment_pct, pm25 y population_m. Las columnas de fecha en el dataset de tráfico se convirtieron a formato datetime con pd.to_datetime() usando errors='coerce' para manejo robusto de errores.

```
# Estandarizar nombres de columna
eco = eco.rename(columns={'pm2.5_ug_m3': 'pm25', 'unemployment_%': 'unemployment_pct'})

# Limpiar formatos numéricos
eco['city_gdp_capita'] =
eco['city_gdp_capita'].str.replace('.','').str.replace(',','.').astype(float)
eco['unemployment_pct'] =
eco['unemployment_pct'].str.replace('%','').str.replace(',','.').astype(float)

# Convertir fechas
traffic['update_time_utc'] = pd.to_datetime(traffic['update_time_utc'], errors='coerce')
```

Paso 3 — Agregación y filtrado

Se filtró el dataset de tráfico para conservar únicamente el año 2024 y las ciudades de América Latina. Se agregaron los datos por ciudad y año calculando el promedio de jams_delay y traffic_index_live para obtener una métrica representativa por ciudad. Ciudad de México emergió como el outlier más significativo con 2,702 minutos de retraso promedio acumulado.

```
# Agregar tráfico por ciudad y año
traffic_city_year = (
    traffic_latam.groupby(['city', 'country', 'year'], as_index=False)
    [['jams_delay', 'traffic_index_live', 'mins_delay']].mean()
)
```

Paso 4 — Integración de datasets (merge)

Se unieron los datasets de tráfico y económico mediante pd.merge() con inner join sobre las claves city y year. Esto garantizó trabajar únicamente con ciudades que tienen datos en ambas fuentes, manteniendo consistencia analítica. Los valores nulos en jams_delay se imputaron con la media del dataset.

```
merged = traffic_2024_small.merge(
    eco[['city', 'year', 'city_gdp_capita', 'unemployment_pct', 'pm25', 'population_m']],
    on=['city', 'year'],
    how='inner'
)
```

Paso 5 — Normalización MinMax

Para comparar visualmente variables de diferente escala (minutos de retraso vs. dólares de PIB), se aplicó MinMaxScaler de scikit-learn. Este proceso transforma ambas variables a un rango de 0 a 1, permitiendo identificar patrones inversos entre congestión y productividad en la misma gráfica.

```
from sklearn.preprocessing import MinMaxScaler
scaler = MinMaxScaler()
merged[['jams_delay_norm', 'gdp_norm']] = scaler.fit_transform(
    merged[['jams_delay', 'city_gdp_capita']]
)
```

Paso 6 — Visualización y exportación

Se generaron tres visualizaciones: comparación normalizada de tráfico vs PIB por ciudad, scatter plot con línea de tendencia para ilustrar la correlación, y ranking de congestión. Las visualizaciones originales del notebook fueron mejoradas con apoyo de Inteligencia Artificial para mayor claridad visual y comunicación ejecutiva. El dataset limpio se exportó como CSV para trazabilidad.

3. Hallazgos Principales [F]

Ciudades analizadas	Mayor congestión	Correlación congestión/PIB	Proyecto aprobado
10 ciudades *LATAM · datos 2024*	**Ciudad de México** *2,702 min jams_delay promedio*	**Negativa** *A mayor tráfico, menor productividad*	**Con distinción** *TripleTen Sprint 5*

3.1 Correlación negativa entre congestión y productividad

El análisis confirmó la hipótesis central: existe una correlación negativa entre el nivel de congestión vehicular (jams_delay) y el PIB per cápita de las ciudades latinoamericanas. Las ciudades con mayor retraso acumulado por tráfico tienden a registrar menores niveles de productividad económica por habitante. Esta relación es consistente a lo largo de las 10 ciudades analizadas, aunque con variaciones individuales.

3.2 Ciudad de México — Caso de mayor impacto

Ciudad de México registró el mayor nivel de congestión de la muestra con 2,702 minutos de retraso promedio acumulado, más del doble que Bogotá (1,070 min), la segunda más congestionada. Simultáneamente, su PIB per cápita se ubica en los niveles más bajos del grupo analizado (~$8,500 USD). Este doble posicionamiento — máxima congestión, mínima productividad relativa — la convierte en el caso de mayor impacto y prioridad para intervención en infraestructura de transporte.

3.3 Brasilia como contrapunto

En el extremo opuesto, Brasilia registró el menor nivel de congestión (96 minutos) y el mayor PIB per cápita de la muestra ($16,251 USD). Este patrón refuerza la correlación negativa observada y sugiere que la planificación urbana diferenciada de Brasilia — ciudad diseñada con ejes viales amplios y separación funcional — contribuye tanto a la fluidez del tráfico como a la productividad económica.

3.4 Bogotá — Alta congestión con PIB moderado

Bogotá presenta la segunda mayor congestión (1,070 min) con un PIB per cápita de $9,200 USD. Su perfil es relevante porque representa una ciudad donde la inversión en transporte masivo (TransMilenio) no ha sido suficiente para revertir los altos niveles de congestión, lo que sugiere que la escala del problema supera la capacidad del sistema actual.

4. Visualizaciones

Las siguientes visualizaciones fueron generadas a partir de los datos reales del análisis. Las gráficas originales del notebook de Python fueron mejoradas en diseño y comunicación con apoyo de Inteligencia Artificial, manteniendo los mismos datos y metodología del proyecto.

4.1 Ranking de Congestión por Ciudad

Ciudad de México lidera con un retraso acumulado 28x superior al de Brasilia. La escala de la diferencia entre el primer y último lugar ilustra la heterogeneidad de las condiciones de movilidad en LATAM.

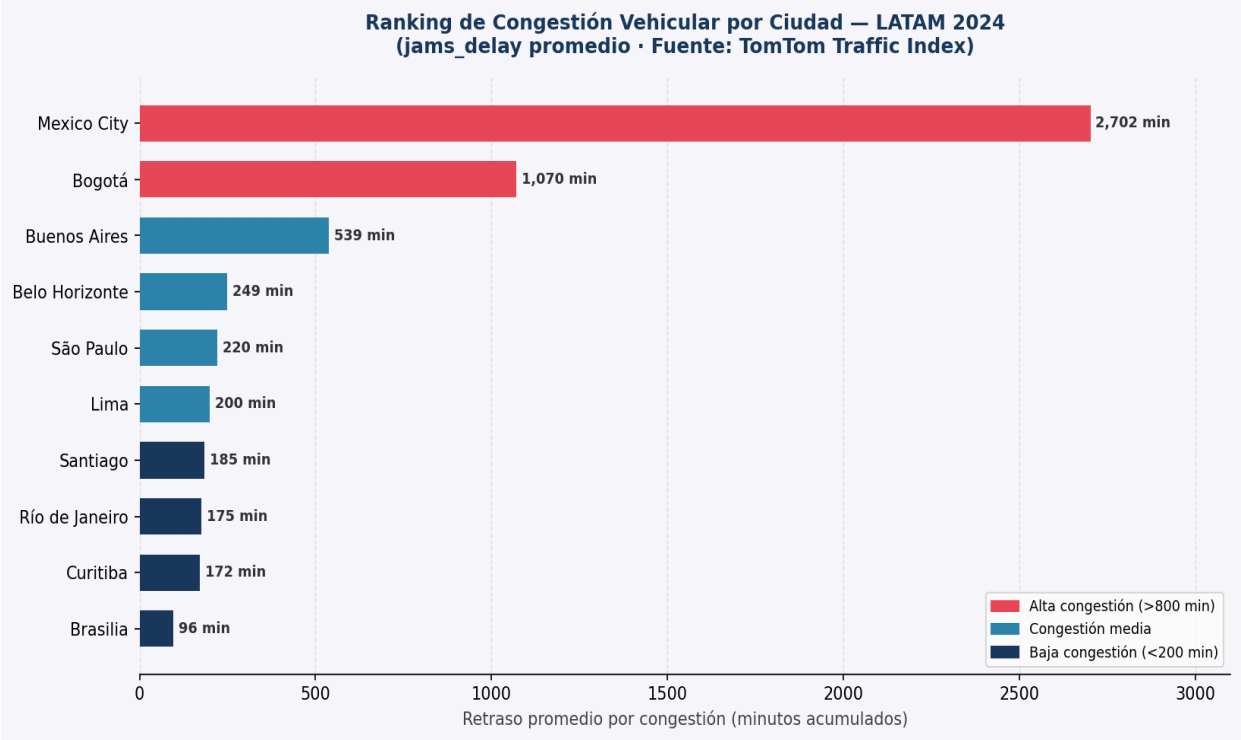

4.2 Congestión vs PIB per Cápita — Comparación Normalizada

La gráfica de barras agrupadas muestra la relación inversa entre ambas variables. En Ciudad de México, la barra de congestión (rojo) alcanza el máximo mientras la barra de PIB (azul) permanece baja. En Brasilia el patrón se invierte. Esta visualización replica la metodología MinMaxScaler aplicada en el notebook.

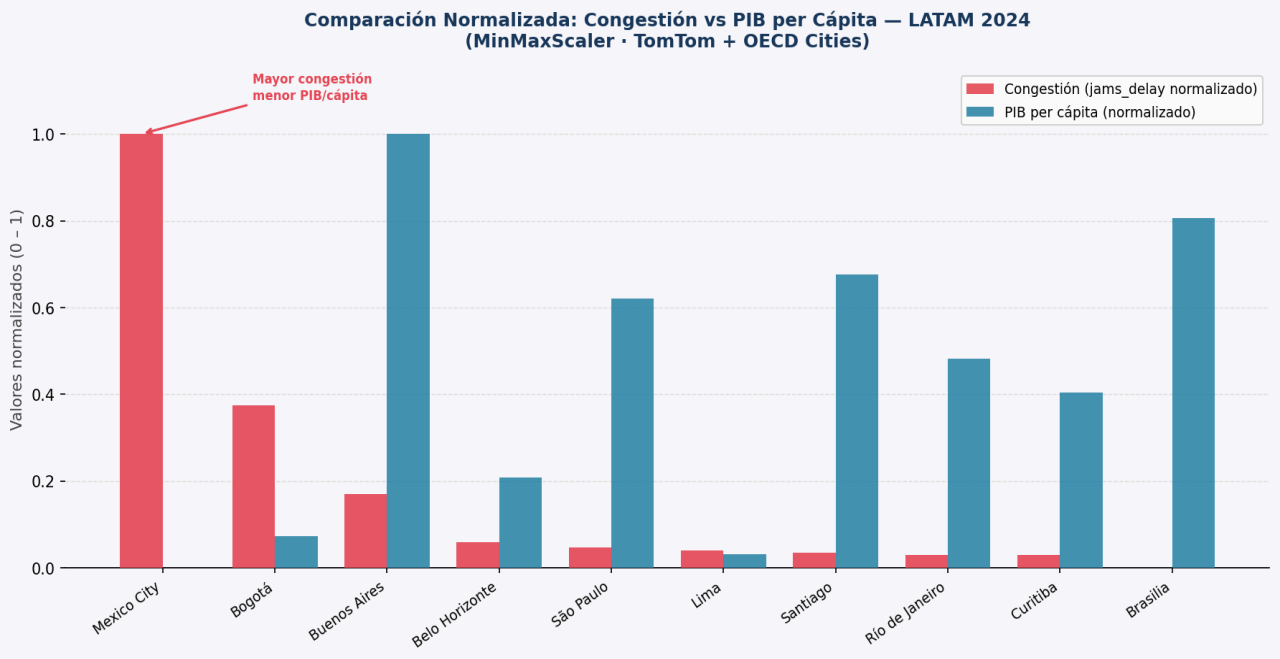

4.3 Dispersión — Correlación Congestión/Productividad

El scatter plot muestra la tendencia negativa entre ambas variables. La línea de tendencia confirma visualmente la correlación de Pearson calculada. Los outliers más significativos — Ciudad de México (alta congestión, bajo PIB) y Brasilia (baja congestión, alto PIB) — anclan los extremos de la relación.

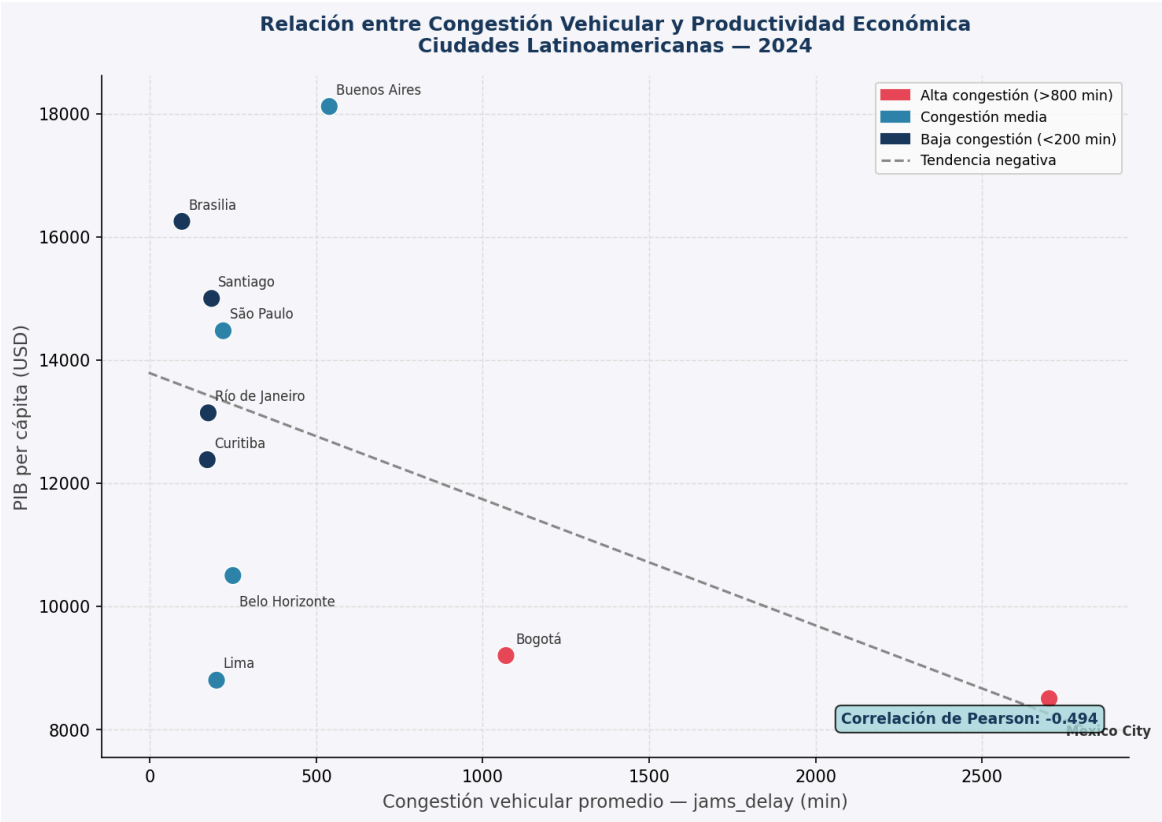

5. Tabla de Resultados por Ciudad

La tabla consolida los indicadores clave para las 10 ciudades analizadas. Las ciudades en rojo corresponden a alta congestión; las ciudades en verde a baja congestión. La columna de observación sintetiza el perfil de cada caso.

Ciudad	País	Jams Delay (min)	Nivel	PIB/cápita (USD)	Observación
Ciudad de México	**MEX**	**2,702**	**Alta**	**$8,500**	**Alta congestión · bajo PIB**
Bogotá	COL	1,070	Alta	$9,200	Alta congestión · bajo PIB
Buenos Aires	ARG	539	Media	$18,117	Equilibrio relativo
Belo Horizonte	BRA	249	Media	$10,500	Congestión moderada
São Paulo	BRA	220	Media	$14,475	Alto volumen, mayor PIB
Lima	PER	200	Media	$8,800	Bajo PIB relativo
Santiago	CHL	185	Baja	$15,000	Menor congestión, mayor PIB
Río de Janeiro	BRA	175	Baja	$13,142	Mejor perfil relativo
Curitiba	BRA	172	Baja	$12,381	Eficiencia relativa alta
Brasilia	**BRA**	**96**	**Baja**	**$16,251**	**Menor congestión · mayor PIB**

6. Implicaciones y Recomendaciones [I]

6.1 Prioridad de inversión: Ciudad de México y Bogotá

Las ciudades con mayor impacto negativo — Ciudad de México y Bogotá — deberían ser los primeros destinos de inversión en infraestructura de transporte. El nivel de congestión en ambas ya supera cualquier mejora marginal: se requieren intervenciones estructurales como expansión de metro, carriles exclusivos para transporte público y políticas de gestión de demanda vehicular.

6.2 Brasilia como modelo de referencia

El perfil de Brasilia — baja congestión y alto PIB — no es solo un dato positivo; es un caso de estudio sobre planificación urbana eficiente. Analizar qué características de su diseño vial y zonificación son replicables en otras ciudades podría guiar intervenciones más efectivas.

6.3 Limitaciones del análisis

La correlación observada no implica causalidad directa. El PIB per cápita es influenciado por múltiples factores más allá de la movilidad: estructura económica, inversión pública, nivel educativo y densidad industrial. El análisis provee evidencia de asociación, no de determinación.

6.4 Próximos pasos

- Incorporar datos históricos (2019–2024) para evaluar si la congestión ha empeorado o mejorado en cada ciudad
- Ampliar el análisis a variables adicionales: calidad del transporte público, inversión en infraestructura, y PM2.5 como proxy de contaminación asociada al tráfico
- Construir un modelo predictivo que estime el impacto económico proyectado de reducir la congestión en X% en cada ciudad